



BANDIRMA ONYEDİ EYLÜL ÜNİVERSİTESİ
ÖMER SEYFETTİN UYGULAMALI BİLİMLER FAKÜLTESİ
YÖNETİM BİLİŞİM SİSTEMLERİ BÖLÜMÜ

YBS3259 - MAKİNE ÖĞRENMESİ DERSİ

PROJE RAPORU

Ekibin Adı: Anivia Game Insight

Ad-Soyad: Betül Tuba Gümüş

Öğrenci No: 2321223208

Proje Konusu: Diyabet Risk Tahmini

1. Proje Konusu ve Problemin Tanımı

Diyabet, dünya çapında sağlık sistemleri üzerinde en büyük mali ve operasyonel yükü oluşturan kronik hastalıklardan biridir. Bu projenin temel odağı, erken teşhis ve karar destek sistemleri entegrasyonu ile bu yükü makine öğrenmesi yöntemleri ile minimize etmektir.

Problemin Stratejik Önemi: Diyabet riski tahmini, yalnızca bireylerin yaşam kalitesini korumakla kalmaz; sağlık kurumları için kaynak planlamasını optimize eder ve tedavi maliyetlerini düşürür.

Analitik Yaklaşım: Projemiz, yalnızca "diyabet var/yok" tahmini yapan bir modelin ötesinde; veri temelli sağlık yönetimi perspektifiyle, yüksek riskli bireyleri önceliklendiren bir mekanizma kurgulamayı hedefler.

İşlevsel Değer: Karar destek mekanizmalarına veri madenciliği yaklaşımıyla sunulacak olan bu tahminleme, klinik süreçlerde "önleyici tıp" uygulamalarına zemin hazırlamaktadır.

2. Kullanılan Veri Seti ve Yapılan İşlemler

Projemizde modelimizi eğitmek için Kaggle platformundan aldığımız, literatürde bir standart haline gelen **Pima Indians Diabetes** veri setini kullandık. Bu veri seti, 21 yaş ve üzeri kadın hastalardan oluşan 768 satırlık ve 9 sütunluk, hacmen küçük ama analiz açısından zorlayıcı bir veri setidir. Bağımlı (hedef) değişkenimiz outcome (1: Diyabetli, 0: Sağlıklı) olup, modeli beslediğimiz bağımsız öznitelikler; hamilelik sayısı, glikoz, kan basıncı, cilt kalınlığı, insülin, vücut kitle indeksi (BMI), genetik risk skoru ve yaşıdır.

- Pregnancies: Hamile kalma sayısı.
- Glucose: Kandaki glikoz konsantrasyonu, kan şekeri.
- Insulin: 2 saatlik serum insülini.
- BloodPressure (Kan Basıncı):Diyastolik kan basıncıdır (halk arasında bilinen adıyla "küçük tansiyon", mm Hg cinsinden ölçülür).
- SkinThickness (Cilt Kalınlığı): Triceps (arka kol) cilt kıvrım kalınlığıdır (mm cinsinden). Genellikle vücut yağ oranını tahmin etmek için kullanılan bir ölçümdür.
- BMI: Vücut kitle indeksi (kilo / boyun karesi).
- Age: Yaş bilgisi.
- **Outcome:** Diyabet durumu (1: Pozitif, 0: Negatif). (Target)

Veriyi doğrudan modellere vermek yerine Keşifçi Veri Analizi (EDA) aşamasında detaylıca inceledik. İlk fark ettiğimiz ve bizi en çok uğraştıran şey; Glucose, BloodPressure, SkinThickness, Insulin ve BMI sütunlarındaki bazı değerlerin "0" olmasıydı. Canlı bir insanın kan basıncının veya glikozunun 0 olması biyolojik olarak imkansızdır. Bunların veri

girişinde "girilmeyen/eksik" veriler olduğunu fark edip, modeli yanıltmamaları için hepsini önce NaN (eksik veri) formatına dönüştürdük.

Eksik verileri doldururken basitçe sütun ortalamasını almak yerine, verinin doğasına daha uygun olan KNN Imputer (K-En Yakın Komşu Ataması) kullandık. Böylece eksik veriye sahip bir hastanın değerini, ona biyolojik olarak en çok benzeyen diğer hastaların verilerine bakarak doldurduk. Ayrıca veri setimizde %65 Sağlıklı, %35 Diyabetli şeklinde bir dengesizlik vardı. Bunu stratify=y ile kontrol altına aldık. Aşırı sağa çarpık olan İnsulin ve genetik risk skorlarında veriyi normale yaklaştırmak için Logaritmik Dönüşüm (Log1p) yaptık ve son olarak aykırı değerlerin (outliers) model üzerindeki baskısını kırmak için verimizi RobustScaler ile ölçeklendirdik.

3. Kullanılan Yöntemler ve Algoritmalar

Bu projenin yönergeleri doğrultusunda, verimizin hangi algoritma mantığıyla daha iyi uyduğunu bulmak için geniş çaplı bir deneme yaptık. Ancak her modeli tek tek kurup zaman kaybetmek yerine, veri bilimi dünyasında oldukça popüler olan Lazy Predict kütüphanesini kullandık.

Bu hızlı tarama sonucunda, verimizdeki özelliklerin birbirinin içine geçtiği doğrusal olmayan yapıyı en iyi çözen 10 temel algoritmayı ve performanslarını şu şekilde raporladık:

1. **BaggingClassifier:** Accuracy: 0.75, ROC AUC: 0.71 skorlarıyla taramanın zirvesinde yer aldı. Sadece 0.11 saniyede eğitimi tamamladı.
2. **LGBMClassifier:** Özellikle dengesiz veri setlerinde çok hızlı çalışması ve histogram tabanlı yapısıyla aykırı değerlere karşı güçlü duruşu nedeniyle birincil odağımız oldu. ROC AUC: 0.71 ve F1-Score: 0.74 ile en güçlü adayımız oldu. Karmaşık yapısına rağmen 4.81 saniyede sonuç döndürdü.
3. **DecisionTreeClassifier:** Sonuçları doğrudan bir "Eğer-Değilse" kuralına döktüğü için, hastanede doktorlara açıklanabilirliği (interpretability) en yüksek temel model olarak kullandık. 0.03 saniye gibi rekor bir sürede 0.71 ROC AUC skoruna ulaşarak ağaç modellerinin başarısını kanıtladı.
4. **XGBClassifier:** Glikoz, yaş ve BMI gibi özelliklerin birbiriyle olan karmaşık (non-linear) etkileşimlerini yakalamada literatürün en güçlü algoritmalarından biri olduğu için kullandık. 2.24 saniyede 0.73 Accuracy ve 0.71 ROC AUC skoruyla yüksek performanslı modeller arasında yerini aldı.
5. **AdaBoostClassifier:** Modelin yanlış tahmin ettiği zor vakalara odaklanarak adım adım öğrenmesi (boosting) stratejisini test etmek istedik.
6. Hatalara odaklanan boosting yapısıyla 0.25 saniyede 0.75 Accuracy ve 0.70 ROC AUC skoruna ulaştı.
7. **RandomForestClassifier:** Karar ağaçlarının aşırı öğrenme (overfitting) riskini torbalama (bagging) yöntemiyle azaltması ve stabil sonuçlar vermesi nedeniyle güvendiğimiz bir modeldi. 0.48 saniyede 0.73 Accuracy sağlayarak modellerimiz arasındaki stabiliteyi temsil etti.

8. **ExtraTreesClassifier**: Random forest'a çok benzer bir yapıda olmasına rağmen ayrımları daha rastgele yaparak varyansı düşürüp düşürmeyeceğini görmek için projeye dahil ettik. 0.41 saniyede eğitilerek 0.72 Accuracy ve 0.68 ROC AUC skoru elde etti.
9. **GaussianNB (Naive Bayes)**: Olasılıksal yaklaşımıyla 0.04 saniyede 0.70 Accuracy ve 0.68 ROC AUC skoru sundu.
10. **KNeighborsClassifier (KNN)**: Sadece matematiksel değil, mantıksal olarak da "benzer hastalar benzer riskler taşır" varsayımının çalışıp çalışmadığını test ettik. Benzer hasta profillerini 0.06 saniyede 0.71 Accuracy ve 0.67 ROC AUC skoruyla grupladı.
11. **Logistic Regression**: Sağlık verilerinde yıllardır bir endüstri standardı olan bu doğrusal modeli, ağaç tabanlı modellere karşı bir temel (baseline) olarak kıyaslamak için kullandık. Sektör standardı olan bu model, 0.69 Accuracy ve 0.65 ROC AUC skorunda kalarak ağaç tabanlı modellerin bu veri setinde neden daha üstün olduğunu bize gösterdi.

Lazy Predict sayesinde ulaştığımız bu sonuçlar; doğrusal modellerin (Logistic Regression gibi) diyabet tahmininde yetersiz kaldığını, Bagging ve Boosting (LGBM, XGBoost) temelli modellerin ise verideki gizli örüntüleri çok daha iyi yakaladığını net bir şekilde ortaya koydu. Bu stratejik öngörüyle projenin devamında LightGBM ve XGBoost modelleri üzerine derinleşerek hiperparametre optimizasyonlarını (GridSearchCV ve RandomizedSearchCV) bu modeller üzerinden kurguladık.

4. Model Eğitimi ve Test Süreci

Modelin daha önce hiç görmediği verilerde nasıl performans sergileyeceğini ölçmek için veri setimizi %80 Eğitim (Train) ve %20 Test olarak ayırdık. Yalnızca 768 satırlık butik bir veri setimiz olduğu için en büyük korkumuz modelin veriyi ezberlemesi idi (Overfitting). Bunu engellemek ve "veri sızıntısı" (Data Leakage) yapmamak için, KNN Imputer gibi tüm ön işleme adımlarımızı önce ayırma işlemini yapıp, sadece eğitim setinden öğrenerek (fit) gerçekleştirdik. Ayrıca modeli değerlendirirken **Stratified 5-Fold Cross Validation** kullandık ki model her katlamada sınıf dengesizliğini eşit oranda görsün.

Optimizasyon aşamasında işin maliyet/zaman boyutunu da hesaba kattık. XGBoost modeli çok fazla parametre içerdiği için hiperparametre okyanusunda kaybolmamak adına **RandomizedSearchCV** ile rastgele ama geniş bir ağ attık (Ağaç sayısı, derinlik ve öğrenme hızı gibi parametreleri taradık). En güçlü adayımız olan LightGBM'de ise milimetrik ince ayar yapmak istediğimiz için **GridSearchCV** kullandık. Eğitim sürecinde, bu optimizasyonların modelimizi ne kadar iyi frenlediğini (Ağaçların gereksiz büyümesini engelleyerek ezberi önlediğini) gözlemledik.

5. Değerlendirme Metrikleri ve Yorumlar

Makine öğrenmesi derslerinde sıkça vurguladığımız gibi, sınıf dengesizliğinin olduğu veri setlerinde (bizimki gibi %65'i sağlıklı olan bir veride) **Accuracy (Doğruluk)** metriğine bakmak büyük bir tuzaktır. Model herkese sadece "Sağlıklı" dese bile otomatikman yüksek bir accuracy skoruna sahip olur. Ancak sağlık sektöründe; gerçekte diyabetli olan bir hastaya yanlışlıkla "Sen sağlıklısın, gidebilirsin" (**False Negative**) demenin faturası hastanın hayatıdır. Bu yüzden bizim gözümüz tamamen **Recall (Duyarlılık)**, **F1-Score** ve **Confusion Matrix (Karmaşıklık Matrisi)** üzerindeydi.

Tüm modeller üzerinde yapılan Grid Search ve Randomized Search optimizasyonları sonucunda, Pima Indians Diabetes veri setinde en yüksek performansı **LightGBM (Light Gradient Boosting Machine)** algoritması göstermiştir.


1. Performans Karşılaştırması ve Seçim Gerekçesi

Aşağıdaki tablo, hiperparametre optimizasyonu sonrası elde ettiğimiz final performans değerlerini özetlemektedir:

Metrik	XGBoost (Optimize)	LightGBM (Optimize)	Fark (LGBM Lehine)
En İyi CV ROC-AUC	0.8351	0.8336	-0.0015
Test ROC-AUC	0.8215	0.8189	-0.0026
Test Accuracy	%75	%76	+%1
Recall (Diyabetli Sınıfı)	%57	%65	+%8
F1-Score (Diyabetli Sınıfı)	0.61	0.65	+0.04

- **Genel Başarı:** LightGBM, test veri setinde %76 Genel Doğruluk ve 0.8189 ROC-AUC skoru ile XGBoost'u geride bırakmıştır.
- **Tıbbi Karar Verme Yeteneği (Kritik Metrik):** Bu problemin doğası gereği asıl amacımız hasta olan kişileri kaçırmamaktır. LightGBM, "Diyabetli" sınıfını yakalama başarısında (Recall) %65'lik bir oran elde ederek (%57'de kalan) XGBoost'a bariz bir üstünlük kurmuştur.

2. Karmaşıklık Matrisi (Confusion Matrix) Analizi



LightGBM modelinin test setindeki 154 hastaya ait tahminleri incelendiğinde:

- **Doğru Tahminler:** 82 sağlıklı ve 35 diyabetli hasta doğru şekilde teşhis edilmiştir (Toplam 117 doğru).
- **Yanlış Alarmlar (False Positive - Tip I Hata):** 18 kişi gerçekte sağlıklı olmasına rağmen "diyabetli" olarak işaretlenmiştir. Tıbbi teşhis sistemlerinde bu durum kabul edilebilir bir risk maliyetidir; hastadan ek test istenerek durum doğrulanabilir.
- **Tehlikeli Hatalar (False Negative - Tip II Hata):** Gerçekte diyabetli olan 19 hastaya yanlışlıkla "sağlıklı" teşhisi konulmuştur. Bu durum projemizde en çok savaş açtığımız tehlikeli hata tipidir.

3. Projenin Sonucu ve İyileştirme Önerileri

Sadece 768 satırlık ve biyolojik eksik verilerle (sıfır değerleri) dolu küçük bir veri seti olan Pima Indians için, **veri sızıntısı (data leakage) yapılmadan ve aşırı öğrenmeye (overfitting) düşmeden elde edilen bu %76'lık LightGBM performansı oldukça başarılı ve dürüst bir sonuçtur.**

Gelecek Adımlar ve Ekip Önerilerimiz:

1. **Eşik Değeri (Threshold) Optimizasyonu:** Modelin karar verme eşiğinin (varsayılan %50), "Tip II Hata"yı daha da azaltmak amacıyla %30-40 bandına çekilmesini öneriyoruz. Bu sayede model daha "şüpheli" davranacak ve kaçırılan hasta sayısı (19) çok daha aşağılara inecektir.
2. **Daha Fazla Veri:** Özellikle "Diyabetli" (Outcome=1) sınıfına ait gerçek hasta verisi toplanarak modelin o sınıfı öğrenme kapasitesi artırılabilir.

Model Konfigürasyon Notları:

- **En İyi XGBoost Parametreleri:** {'subsample': 0.6, 'scale_pos_weight': 1, 'n_estimators': 300, 'max_depth': 4, 'learning_rate': 0.01}
- **En İyi LightGBM Parametreleri:** {'class_weight': None, 'learning_rate': 0.05, 'max_depth': 3, 'n_estimators': 100}